

Користење на CNN за предвидување што е во фокусот на вниманието според EEG сигнали

Апстракт—Brain-Computer Interface (BCI) се потпира на алгоритмите од машинско учење за декодирање на сигналите на мозокот. Откривањето на P300 сигналот е значителен предизвик при обработка на EEG сигналот, пред се заради комплексните и нестационарни карактеристики на EEG. Точното откривање на P300 во EEG податоци може да се користи за дизајнирање на BCI за подобрување на социјалното внимание кај лица со аутизам.

За ваквата цел од неодамна масовно почнаа да се користат Конволуциските невронски мрежи (CNN), но секако притоа треба да се земе во предвид и комплексноста на ваквите модели. Во ова истражување се користи EEGNet, компактна CNN наменета за интерпретација и класификација на EEG сигнали. Со ваквата мрежа и соодветно подесување на нејзините параметри, добивме модел кој има задоволителна точност на тренинг, но и на тест податоците (86.22%).

Index Terms—Event-Related Potential(ERP), Brain-Computer Interface(BCI), P300 detection, Convolutional Neural Network(CNN), Autism-Spectrum Disorder

I. Вовед

Аутизмот и аутистичниот спектар на нарушувања е низа на невноразвојни нарушувања кои што се карактеризираат со проблеми во социјалната комуникација и социјалната интеракција, повторувачки начини на однесување, интереси или активности. Долгорочните проблеми може да вклучуваат потешкотии во креирањето и одржувањето на врските, задржувањето на работата и извршувањето на секојдневните задачи. Причинителот на нарушувањата од аутистичниот спектрум не е сигурно познат и токму затоа овој проблем е предмет на многу истражувања, меѓу кои и ова. Повеќе истражувања покажале дека со користење на EEG сигналите и нивна анализа можно е да се подобрат социјалните вештини на аутистичните лица.

EEG (Електроенцефалографија) претставува дијагностичка метода кој ја покажува биоелектричната активност во мозокот. Клетките во мозокот комуницираат преку примање и предавање на електрични импулси и тоа примопредавање се врши цело време, дури и кога спиеме. Таа активност се прикажува како бранови облици на EEG записот и со помош на електроди кои се поставени на површината на черепот се регистрира биоелектрична активност на мозокот во вид на одредени графоеlementи.

Event-related potential (ERP) е електричен сигнал кој се појавува во мозокот како резултат на некаков стимул, а конкретно предмет на ова истражување ќе биде детекцијата на сигналот p300. Ваквиот проблем е ос-

новата на специфичен тип на Brain-Computer Interface (BCI) кој што го истражува фактот дека вниманието кон специфичен, редок стимул во однос на други стимули, генерира позитивен раст во EEG сигналот околу 300ms по стимулот, т.е се јавува сигналот P300.

За детекција на сигналот P300 ќе користиме Конволуциска невронска мрежа, поточно EEGNet. Неодамна, Конволуциските невронски мрежи (Convolutional Neural Networks - CNN) постигнаа извонредни перформанси во компјутерска визија и се покажаа како корисни алатки за декодирање на сигнали и анализа на различни комплексни домени. Овие модели автоматски ги учат најважните карактеристики и овозможуваат од-почеток-до-крај (end-to-end) систем за класификација.

II. Податочно множество

Во ова истражување се користи податочното множество обезбедено од натпреварот на IFMBE (International Federation of Medical and Biological Engineering) од 2019 година [1]. EEG сигналите се собрани од 15 учесници кои имаат аутистични нарушувања, и се добиваат од 8 електроди позиционирани на локациите C3, Cz, C4, CPz, P3, Pz, P4, POz.

За да се соберат ваквите податоци е креирана виртуелна соба со мебел и 8 различни објекти. При изведување на експериментот избран е еден таргет објект кој ќе светне неколку пати, а учесникот е известен кој е овој објект и треба да брои колку пати ќе светне. При секое светнување на објектот на кој учесникот му обраќа внимание (а тоа очекуваме да биде таргет објектот) се генерира P300 сигналот. Експериментот е изведен во две фази и секој учесник има три сесии во првата фаза и четири сесии во втората. Во ова истражување се разгледува само првата фаза. Во секоја од сесиите тест множеството има 50 блока, а тренинг податоците имаат 20 блока кои имаат по 10 runs. Во секој run на експериментот светкаат 8-те објекти еден по еден. Вкупно има 8 евенти во еден run, 80 евенти во еден блок, т.е 1600 евенти во една сесија (200 таргет). Целта е да го дизајнираме најдобриот модел кој ќе ги одреди таргет објектите во фазата на тестирање.

III. Методологија

A. Претпроцесирање

Во делот на претпроцесирање се користат неколку методи. Најпрво, иако сигналот (Слика 1) е веќе фи-

лтриран со 2–30 Hz band-pass филтер, се уште има шум во релативно повисоките фреквенции, за да се ублажи овој шум, беше направен дополнителен 20 Hz Butterworth low-pass filter [2] – добиениот сигнал се нарекува и „maximally flat“ сигнал или сигнал без бранување бидејќи филтерот е дизајниран неговиот излез да биде толку пораман колку што е математички возможно и ги пропушта сигналите со фреквенција пониска од 20 Hz (Слика 2).




Слика 1: Визуелизација на сигналот од последниот канал за еден настан.



Слика 2: Сигналот по филтрирањето со 20Hz 6th order Butterworth low-pass филтер.

Дополнително, сигналите се ресемплирани од 250Hz на 128Hz, со цел да се намали цената за процесирање, што резултира со 179 time samples (точки) за еден настан (Слика 3), а воедно и да се обезбеди компатибилност со конволуциската мрежа која ќе се користи за тренирање на моделите.

Потоа е направена Z-скор нормализација (стандардизација) на сигналот (Слика 4), бидејќи невронските мрежи се зависни од вредностите на карактеристиките, односно доколку карактеристиките имаат голем ранг



Слика 3: Сигналот по ресемплирањето на 128Hz.

во кој се наоѓаат нивните вредности можат да се добијат полоши резултати [3]. Затоа правиме нормализација на овие вредности со цел да добиеме модел на невронска мрежа кој што е многу подобар, односно тоа ќе доведе до поквалитетно тренирање во мрежата.

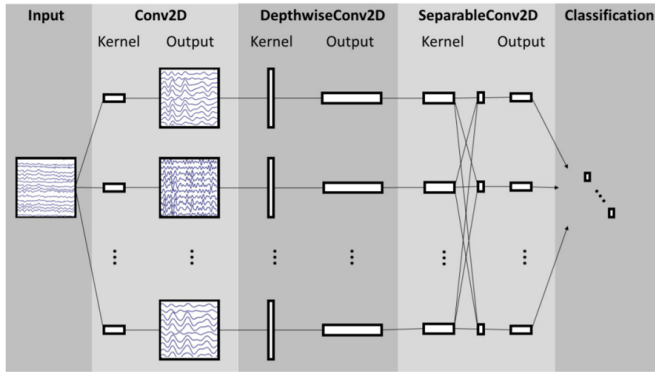


Слика 4: Сигналот по Z-скор нормализација.

Како што е објаснето претходно, во тренирачкото множество, во секој run има по 8 настани од кои само еден е P300. Според тоа може да се заклучи дека тренирачкото множество е доста небалансирано (во една сесија односот помеѓу единици и нули е 1 : 7). Со цел да се намали небалансираноста, направен е random undersampling [4], така што крајниот однос помеѓу класите е 1 : 4, со тоа што дополнително на класите им се доделени и соодветни тежини. Исто така, за секој учесник има посебен модел со оглед на тоа што EEG сигналите варираат од индивидуа до индивидуа. Тренирачкото множество за секој учесник ги содржи трите сесии, што значи дека по претпроцесирањето има облик 3600 x 1 x 8 x 179.

В. Модел

За декодирање на P300 сигналот беше користена EEGNet [5] која е компактна CNN наменета за интерпретација и класификација на EEG-базирани BCIs, дизајнирана да го намали бројот на тренирачки параметри со вклучувањето на Depthwise и Separable конволуции (Слика 5). Кај првите CNN дизајнирани за детекција на P300 сигналот прво се изведува конволуција во просторен домен за автоматска екстракција на просторните карактеристики од EEG сигналот, а потоа конволуција во временски домен во подлабоките слоеви. Но подоцна се покажало дека, во споредба со овие архитектури, подобри резултати се добивале ако конволуција во временски домен се прави и во првиот слој. Поради оваа причина ние се одлучивме да користиме EEGNet каде прво се изведува конволуција во временски домен, проследена со конволуција во просторен домен и конволуција во временски домен во подлабоките слоеви.



Слика 5: Визуелизација на EEGNet архитектурата [5].

Оваа CNN вклучува 3 блока. Во првиот блок има два конволуциски слоја кои што прават temporal и depthwise spatial конволуции. Оваа мрежа претпоставува дека влезниот сигнал е семплиран на 128Hz, па затоа во фазата на претпроцесирање направивме соодветно ресемплирање. Мрежата почнува со 2D конволуциски слој (temporal convolution) за да научи фреквенциски филтри, а потоа со користење на Depthwise Convolution (depthwise spatial convolution), поврзан со секоја feature мапа посебно, за да научи просторни филтри за секој фреквенциски филтер (frequency-specific spatial филтри). Секој конволуциски слој е проследен со Batch Normalization за нормализирање на влезната feature мапа. На крај, пред да се направи подсемплирање со average pooling слој со големина (1, 4), се применува ELU нелинеарната активациска функција. Исто така за да се избегне висока варијанса и overfitting и да се постигне подобра генерализација се користи и Dropout слој.

Во вториот блок се користи Separable Convolution слој, односно прво се изведува depthwise convolution со

големина (1, 16) проследено со pointwise convolution. Овој слој е проследен со Batch Normalization. Исто како и во претходниот блок се применува ELU нелинеарната активациска функција и потоа се прави подсемплирање со average pooling слој со големина (1, 8) за намалување на димензионалноста и на крај се користи Dropout слој.

Во последниот односно класификацискиот блок пред да се предадат карактеристиките на softmax слојот кој ја финализира бинарната класификација, има fully-connected слој за агрегација на карактеристиките.

Главните хипер-параметри и сите останати параметри на мрежата (K - number of kernels, F1 - number of temporal filters, F2 - number of pointwise filters, D - number of spatial filters to learn within each temporal convolution, F - size of the kernels, p - dropout rate) се подесени според спецификациите во [5] прикажани во Табела 1.

LAYER (TYPE)	OUTPUT SHAPE	HYPER-PARAMETERS	PARAM #	ACTIVATION
InputLayer	(None, 1, 8, 179)			
Conv2D	(None, 8, 8, 179)	K = 8	520	Linear
		F = (1, 65)		
BatchNormalization	(None, 8, 8, 179)		32	
DepthwiseConv2D	(None, 16, 1, 179)	D = 2	128	Linear
		K = 16		
BatchNormalization	(None, 16, 1, 179)	F = (8, 1)	64	
Activation	(None, 16, 1, 179)			ELU
AveragePooling2D	(None, 16, 1, 44)	F = (1, 4)		
Dropout	(None, 16, 1, 44)	p = 0.4		
SeparableConv2D	(None, 16, 1, 44)	K = 16	528	Linear
		F = (1, 17)		
BatchNormalization	(None, 16, 1, 44)		64	
Activation	(None, 16, 1, 44)			ELU
AveragePooling2D	(None, 16, 1, 5)	F = (1, 8)		
Dropout	(None, 16, 1, 5)	p = 0.4		
Flatten	(None, 80)			
Dense	(None, 2)	max norm = 0.25	162	Linear
Activation	(None, 2)			Softmax

Табела 1. Спецификации за EEGNet

С. Тренинг

За да се изградат моделите најпрво беше потребно да се најдат соодветните параметри за иницијализација за да се максимизира точноста на предвидување (ассигура) и да се минимизира вредноста на функцијата на загуба (loss).

При тренирањето на моделите за валидација беа одделени 25% од податоците. Како функција на загуба беше користена categorical crossentropy. Исто така беше користен оптимизаторот Adam со default-ните вредности за параметрите и ратата на учење, за минимизирање на вредноста на функцијата на загуба [6]. По

повеќе обиди со пробување, како најсоодветни вредности за `batch_size` и `epochs` беа одбрани `batch_size` од 32 и максималниот број на епохи беше подесен на 300 епохи. За справување со небалансираноста беше користен `random undersampling`, така што крајниот однос помеѓу класите беше 1 : 4, со тоа што дополнително на класите им беа доделени и соодветни тежини (параметарот `class_weight`). За да се спречи потенцијален `overfit` за време на тренирањето, покрај вклучувањето на Dropout слој, дополнително беше користена и Early Stopping методата за да се прекине тренирањето кога функцијата на загуба ќе го достигне својот минимум, при што параметарот `patience` (број на епохи пред да се прекине тренирањето откако ќе го достигне минимумот, односно откако ќе почне да расте) беше подесен на 20 за да се спречи `underfitting`.

D. Тестирање

Слично како и за тренирачките множества, за секое тестирачко множество беа направени истите чекори на претпроцесирање и соодветно, на ист начин како и при тренирањето, беа креирани влезните тестирачки матрици.

Класификацискиот модел со `predict` враќа матрица со веројатностите дека даден настан припаѓа на одредена класа (1 – P300, 0 – не е P300), која потоа ја предаваме на функцијата `argmax` за да ги добиеме предвидените класи.

Добиените единици и нули се множат со целните настани и за секој `gup` се добива по еден настан кој бил P300, потоа со наоѓање на модата од секој `gup` во еден блок добиваме кој е целниот објект во тој блок, односно на кој објект учесникот посветил внимание во соодветниот блок.

IV. Резултати и дискусија

Во овој дел се отвара дискусијата околу резултатите и квалитетот на истите. За да се оцени ефикасноста на моделот, се пресметуваат неколку метрики. Точноста, најинтуитивната мерка за пресметка на перформансите на моделот, се добива како сооднос од број на точни предвидувања и вкупниот број на сите предвидувања. Добиена е точност од 86.22%. Генерално оваа вредност е доста задоволителна, но точноста не е секогаш најдекувантната мерка.

Затоа неизбежно е пресметувањето на други параметри, како прецизност и одзив, за квалитетно читање на резултатите. Прецизност и одзивот се пресметани за секоја класа поединечно. Прецизност, однос меѓу точно предвидените позитивни набљудувања и вкупниот број на позитивни предвидени, дава одговор на прашањето, пример за класата 1, кога било предвиден таргет 1, колку од нив биле точно предвидени? Додека одзив, сооднос меѓу точно предвидени позитивни лабел и сите предвидувања од таа класа, дава одговор на, пример за класа 1, кога е вистински 1 таргетот

колку често е предвидено 1? Истото за сите класи. Прецизност се движи од 0.80 до 0.93. Одзивот се движи од 0.69 до 0.94. И двете имаат генерално добри вредности.


Со F1 score, тежинска средина на прецизност и одзивот, се земаат во предвид и грешно позитивно предвидени и грешно негативни предвидени набљудувања. Нејзините високи вредности (од 0.78 до 0.89), како и вредностите на претходните пресметки ги потврдуваат добрите перформанси на моделот (Слика 6).

Classification accuracy on example test data: 0.862222

	precision	recall	f1-score	support
1	0.80	0.94	0.87	278
2	0.87	0.90	0.88	296
3	0.84	0.94	0.89	300
4	0.87	0.87	0.87	281
5	0.90	0.69	0.78	261
6	0.90	0.81	0.85	256
7	0.92	0.83	0.87	287
8	0.83	0.90	0.86	291
accuracy			0.86	2250
macro avg	0.87	0.86	0.86	2250
weighted avg	0.87	0.86	0.86	2250

Слика 6: Classification report

За крај, како уште една претстава на резултатите, се креира и confusion матрица (Слика 7). Процентот на точно предвидени целни објекти се сместени на дијагоналата на матрицата. Најголемите вредности се наоѓаат на оваа дијагонала. Поради ова, како и со самото обојување на матрицата, најзатемнети бои се по дијагоналата, а останатите полиња се светли, јасно е дека моделот прави добри предвидувања



Слика 7: Матрица на конфузија

V. Заклучок

Во нашиот труд ние предлагаме модел чија цел е да го детектира појавувањето на P300 сигналот за да откриеме во кој објект гледа даден учесник. Моделот кој

што го користиме е всушност конволуциска невронска мрежа, поточно EEGNet која што е наменета токму за класификација на EEG сигнали. Со помош на претпроцесирачките методи коишто ги наведовме и објаснивме погоре во трудот, ние успешно ги подготвивме податоците за да и овозможиме на мрежата што е можно подобро класифицирање. Друг проблем со кој се соочивме беше небалансираноста на множеството, за кој што веќе спомнавме дека го решивме со random undersampling.

Со оглед на тоа дека работевме со податоци коишто варираат кај секоја индивидуа, имавме посебен модел за секој учесник. Сите овие чекори беа клучни и повеќе или помалце придонесоа во перформансите на самиот модел. Како крајна целина добивме модел за кој што можеме да кажеме дека успешно го детектира P300 сигналот. Точноста на моделот изнесува 86.22% што е прилично задоволително со оглед на комплексноста на проблемот.

References

- [1] MEDICON 2019 Scientific Challenge Dataset Description, Available at: <https://www.medicon2019.org/wp-content/uploads/ChallengeMediconDatasetDescription.pdf>
- [2] Bougrain, L., Saavedra, C., Ranta, R.: Finally, what is the best filter for P300 detection?. TOBI Workshop III- Tools for Brain-Computer Interaction , Würzburg, Germany. fhal-00756669f (2012, March)
- [3] Mind Media BV. NeXus: Z-score for neurofeedback. Available at: <http://81.169.139.131/download/Whitepaper/BioTrace-NeXus-ZScore-V1.0.pdf> (2012)
- [4] Dealing with Imbalanced Data, Available at: <https://towardsdatascience.com/methods-for-dealing-with-imbalanced-data-5b761be45a18>
- [5] Lawhern, V.J., Solon, A.J., Waytowich, N.R., Gordon, S.M., Hung, C.P., Lance, B.J.: EEGNet: a compact convolutional neural network for EEG-based braincomputer interfaces. J. Neural Eng. 15(5), 056013 (2018)
- [6] Kingma, D.P., Ba, J.: Adam: A method for stochastic optimization. arXiv preprint (2014)